

Relatório de Aprendizado de Máquina: Classificação de Resultados de Suporte

Arthur Felipe Reis Souza

Professores: Gisele Lobo Pappa e Lourenco Ribeiro Grossi Araujo

8 de Novembro, 2025

Introdução

O trabalho visa resolver um problema de classificação binária levantado pelo Jardim Comunitário Raízes Vivas, focando no uso de técnicas de Machine Learning e pré-processamento de dados. O objetivo é desenvolver um modelo preditivo capaz de determinar o ‘**support_outcome**’ para membros do programa, classificando-o como “bom” (good) ou “ruim” (bad).

Para realizar esta tarefa, utilizamos um conjunto de dados de treinamento fornecido no moodle (800 amostras e 21 atributos), detalhando o perfil demográfico, financeiro e histórico de participação de cada membro. Este relatório detalha a metodologia de pré-processamento, a seleção de atributos e a subsequente implementação e ajuste de quatro modelos de classificação distintos:

- Árvore de Decisão (Decision Tree)
- Floresta Aleatória (Random Forest)
- Aumento de Gradiente (Gradient Boosting)
- Classificador Bayesiano (Gaussian Naive Bayes)

Os modelos são avaliados usando validação cruzada (K-Fold Cross-Validation com $k=5$) e comparados com base nas métricas acurácia e a AUC de cada modelo. Para encontrar o melhor modelo de cada algoritmo, a técnica de grid-search também foi aplicada.

Desenvolvimento

O desenvolvimento do projeto foi dividido em três etapas principais: pré-processamento dos dados, definição das métricas de avaliação e, por fim, o treinamento e otimização dos modelos.

1. Pré-processamento e Análise

A qualidade dos dados de entrada é fundamental para o desempenho do modelo, sendo assim, fiz uma análise das colunas para extrair o máximo de informação possível.

Tratamento de Dados Ausentes: Uma análise inicial revelou que o atributo `other_support_plans` continha 649 valores ausentes em 800 amostras (mais de 81%). Devido ao grande numero de valores faltantes, usar eles como input seria pouco confiável. Portanto, esta coluna foi removida do conjunto de dados.

Análise da Variável target: A variável target `support_outcome` mostrou-se desbalanceada, com 70% das amostras classificadas como "good" e 30% como "bad".

Codificação de Atributos Categóricos: Os atributos categóricos foram tratados de acordo com sua natureza (nominal ou ordinal) usando um `ColumnTransformer` do Scikit-learn.

- **Atributos Ordinais:** Atributos com uma ordem intrínseca (ex: `garden_points_status`, `personal_reserve_status`, `role_skill_tier`) foram codificados usando `OrdinalEncoder` para preservar sua relação de classificação.
- **Atributos Nominais:** Atributos sem ordem (ex: `project_focus_code`, `housing_situation`) foram codificados usando `OneHotEncoder` para criar variáveis "dummy".

Os atributos numéricos foram mantidos em sua escala original (`passthrough`), pois os modelos baseados em árvore não são sensíveis à escala dos atributos. O `id` foi removido. O dataset processado final contém 48 atributos.

2. Métricas de Avaliação

No fito de comparar os modelos, utilizamos duas métricas padrão para classificação.

Acurácia (Accuracy): Mede a proporção de previsões corretas sobre o total. É definida como:

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN}$$

Onde VP (Verdadeiro Positivo) e VN (Verdadeiro Negativo) são as classificações corretas, e FP (Falso Positivo) e FN (Falso Negativo) são os erros.

Área sob a Curva ROC (AUC-ROC): A AUC-ROC é uma medida robusta utilizada em problemas de classificação, gerada ao variar o threshold de um classificador e calculando a área da curva final. A curva ROC plota a Taxa de Verdadeiros Positivos (TPR) contra a Taxa de Falsos Positivos (FPR) em vários limiares de decisão, sendo mais próximo de 1 melhor.

$$\text{TPR (Sensibilidade)} = \frac{VP}{VP + FN}$$

$$\text{FPR} = \frac{FP}{FP + VN}$$

Iremos sempre comparar a AUC em relação ao modelo aleatório, considerando-se que ele terá AUC de 0.5. Se for maior que 0.5, representa que o modelo tem alguma capacidade preditiva melhor que o modelo randomico.

3. Modelos Baseados em Árvore

Estes modelos funcionam dividindo sequencialmente os dados com base nos limiares dos atributos. A "qualidade" de uma divisão é medida por critérios de impureza (Gini ou Entropia).

Modelo 1: Árvore de Decisão

Uma única árvore de decisão foi treinada e otimizada via `GridSearchCV`. O modelo atingiu uma **Acurácia Cross-Validation de 0.6800** e uma **AUC de 0.68**. Este desempenho, o mais baixo entre os modelos testados, é esperado, pois árvores únicas tendem a ter alta variância e sobreajustar (overfit) aos dados de treino. Sendo assim, a idéia do trabalho foi testar algoritmos como o Random Forest, que irão reduzir essa variância das árvores de decisão.

Modelo 2: Floresta Aleatória (Random Forest)

Este modelo de ensemble (ensemble é a composição de N modelos para criar um preditor ou regressor final) reduz a variância ao construir múltiplas árvores de decisão em subconjuntos aleatórios dos dados e atributos. Após a otimização com `GridSearchCV`, o modelo alcançou a maior performance geral: uma **Acurácia Cross-Validation de 0.7525** e uma **AUC de 0.79**. Os melhores hiperparâmetros encontrados foram: `'max_depth': 10`, `'max_features': 0.5`, `'min_samples_leaf': 1`, `'min_samples_split': 10`, `'n_estimators': 200`.

Modelo 3: Aumento de Gradiente (Gradient Boosting)


Este modelo também de ensemble constrói árvores sequencialmente, onde cada nova árvore corrige os erros residuais da árvore anterior. Esse modelo tem como objetivo combinar weak learners para reduzir o viés de um modelo, diferentemente do Random Forest que tem como objetivo reduzir a variância das árvores. A otimização com `GridSearchCV` resultou em uma **Acurácia Cross-Validation de 0.7350** e uma **AUC de 0.75**. Os melhores hiperparâmetros encontrados foram: `'learning_rate': 0.05`, `'max_depth': 10`, `'min_samples_leaf': 10`, `'min_samples_split': 10`, `'n_estimators': 200`.

4. Modelo Probabilístico: Naive Bayes


Para fins de teste, utilizei um modelo simples e não baseado em árvores. O classificador Naive Bayes é um modelo probabilístico baseado no Teorema de Bayes, que assume que os atributos são independentes, resultando em um reduzido custo computacional. Esse modelo, por assumir dados independentes e geralmente gerados por distribuições normais, é considerado ter um alto viés. Utilizamos o `GaussianNB`, que assume que os atributos contínuos seguem uma distribuição normal. Este modelo foi notavelmente rápido, mas alcançou a menor **Acurácia Cross-Validation de 0.6663**, e uma **AUC de 0.73**.

5. Análise Visual dos Resultados

As matrizes de confusão (Figuras 1 e 2) fornecem uma visão detalhada dos erros de cada modelo no conjunto de validação. A Figura 1(a) (Árvore de Decisão) mostra uma tendência em classificar "good" como "bad" (30 Falsos Negativos) com mais frequência do que o inverso (26 Falsos Positivos), enquanto os modelos de ensemble (Figuras 1(b) e 2(a)) são mais balanceados.




(a) Decision Tree (CV Acc: 0.680)




(b) Random Forest (CV Acc: 0.753)

Figure 1: Matrizes de Confusão: (a) Árvore de Decisão, (b) Floresta Aleatória



(a) Gradient Boosting (CV Acc: 0.735)



(b) Gaussian Naive Bayes (CV Acc: 0.666)

Figure 2: Matrizes de Confusão: (a) Gradient Boosting, (b) Gaussian Naive Bayes

Conclusão

Concluindo, esse projeto comparou quatro algoritmos de Machine Learning na tarefa de prever o resultado de suporte em um programa de horta comunitária. O pré-processamento foi realizado cuidadosamente, com a remoção de atributos contendo alguns dados ausentes (mais de 80% na coluna `other_support_plans`) e o uso de codificadores ordinais e nominais, foi crucial para o sucesso dos modelos. A avaliação dos modelos foi realizada usando validação cruzada de 5 folds (5-Fold CV) para Acurácia, e uma divisão de validação (20% dos dados) para a geração da curva AUC. Os resultados são resumidos abaixo:

Modelo	Acurácia Média (CV)	AUC (Validação)
Random Forest	0.7525	0.79
Gradient Boosting	0.7350	0.75
Decision Tree	0.6800	0.68
Gaussian Naive Bayes	0.6663	0.73

Análise dos Resultados

Os resultados confirmam o poder dos métodos de ensemble (Random Forest e Gradient Boosting), que superaram significativamente a Árvore de Decisão única e o Naive Bayes. O **Random Forest** foi o modelo de melhor desempenho, alcançando a maior Acurácia em validação cruzada (0.7525) e a maior AUC (0.79) no conjunto de validação.

A Figura 3 demonstra visualmente a superioridade do Random Forest. Sua curva (AUC 0.79) está notavelmente mais próxima do canto superior esquerdo, indicativo de ser um melhor classificador em comparação com o Gradient Boosting (0.75), Naive Bayes (0.73) e a Árvore de Decisão (0.68).




Figure 3: Comparação da Curva ROC para todos os modelos no conjunto de validação.

Recomendação Final

Por fim, com base nesta análise, recomenda-se à coordenação do Jardim Comunitário Raízes Vivas a implementação do modelo **Random Forest** para a tarefa de previsão.

Ele alcançou a maior acurácia em validação cruzada (0.7525) e a maior AUC (0.79) no conjunto de validação, e também pode ser treinado em paralelo., demonstrando ser o modelo mais robusto e com melhor capacidade de generalização para este problema. O arquivo de submissão final `submission.csv` foi gerado pelo Random Forest. Vale lembrar também que essa é apenas a primeira entrega do trabalho, e outros algoritmos, como as redes neurais profundas, podem ser mais efetivos para essa base de dados.