

30 de outubro de 2025

Ao Cientista de Dados Convidado

Caro(a) Cientista de Dados,

Escrevemos em nome de toda a comunidade do **Jardim Comunitário Raízes Vivas**, um espaço que nasceu do encontro entre vizinhos que acreditam na força da colaboração, da solidariedade e do cuidado mútuo. O nosso jardim é mais do que um conjunto de canteiros; ele é um organismo vivo, cultivado por mãos diversas e sustentado por valores coletivos.

Com o passar dos anos, o projeto cresceu. Hoje, contamos com centenas de participantes, pessoas de diferentes idades, profissões e histórias que se reúnem com o mesmo propósito: cultivar alimentos, aprender em conjunto e fortalecer o tecido social do bairro. No entanto, como toda iniciativa humana, enfrentamos desafios. Percebemos que algumas pessoas se envolvem intensamente e permanecem conosco por muito tempo, enquanto outras acabam se afastando, às vezes por dificuldades pessoais, às vezes por falta de apoio adequado.

Essa variação no engajamento nos fez refletir. Como podemos compreender melhor os fatores que influenciam a participação contínua? Como identificar, a tempo, aqueles que talvez precisem de um incentivo, de uma escuta ou de um suporte extra? É aqui que o seu papel se torna essencial.

Convidamos você para atuar como nosso parceiro científico, utilizando os dados que coletamos ao longo dos anos para realizar duas tarefas fundamentais:

1. **Análise Exploratória dos Dados:** investigar as informações que temos sobre nossos membros, buscando compreender padrões que possam nos revelar o que sustenta o engajamento.
2. **Modelagem Preditiva:** desenvolver e comparar modelos capazes de prever o comprometimento futuro de novos participantes. Não buscamos identificar “bons” ou “maus” membros, queremos compreender quem talvez enfrente dificuldades para se manter ativo, de modo que possamos oferecer suporte.

Com sua ajuda, poderemos planejar melhor nossos recursos, personalizar a comunicação com os voluntários e garantir que cada pessoa se sinta parte essencial do Jardim.

Com gratidão e expectativa,

Atenciosamente,

Coordenação do Jardim Comunitário
Raízes Vivas

Instruções Técnicas do Trabalho

Serão disponibilizados dois arquivos principais:

- **df_train.csv** — conjunto de dados rotulado, utilizado para treinamento e validação dos modelos;
- **df_test.csv** — conjunto de dados não rotulado (sem o valor verdadeiro da variável alvo), utilizado para gerar as previsões finais.

O seu papel é realizar as tarefas solicitadas pela comunidade, estruturando o trabalho conforme as etapas de um projeto completo de aprendizado de máquina.

Tarefas Principais:

1. **Análise Exploratória:** realizar uma caracterização detalhada dos dados. A análise deve incluir aspectos descritivos e visuais, permitindo compreender o comportamento dos membros do jardim.
2. **Modelos Preditivos:** desenvolver e avaliar diferentes modelos de aprendizado de máquina capazes de prever o nível de comprometimento dos participantes. Essa etapa deve incluir pré-processamento, engenharia de variáveis, tratamento de valores faltantes, tuning de hiperparâmetros e comparação entre modelos. Usar a coluna "*support_outcome*" como target.

O foco do trabalho não é apenas alcançar a melhor métrica, mas demonstrar clareza no raciocínio analítico, justificativa das escolhas e boas práticas de desenvolvimento.

Entregas Obrigatórias:

1. **Notebook completo (.ipynb)** com todo o código, análises e explicações realizadas;
2. **Relatório em PDF (.pdf)** de no máximo **5 páginas**, apresentando os resultados, conclusões e principais visualizações. O relatório deve ser escrito como se fosse uma devolutiva técnica à comunidade do Jardim, destacando as descobertas, métodos aplicados e recomendações práticas;
3. **Arquivo CSV (.csv)** com duas colunas obrigatórias:
 - **id** — identificador da amostra;
 - **y_pred** — valor previsto pelo modelo.

As métricas de avaliação do modelo serão calculadas automaticamente durante a correção. Garanta que o arquivo **csv** final siga exatamente o formato solicitado, respeitando o nome e a ordem das colunas.

Formato de Entrega e Nomenclatura dos Arquivos

O aluno deve enviar uma única pasta compactada no formato **.zip**, contendo os três arquivos mencionados acima. A pasta deve obrigatoriamente seguir o seguinte padrão de nomeação:

`tp_final_{nome_completo}.zip`

Por exemplo:

`tp_final_joao_guimaraes_rosa.zip`

Dentro da pasta compactada, os arquivos devem estar nomeados exatamente da seguinte forma:

- `notebook_tp_final.ipynb`
- `relatorio_tp_final.pdf`
- `predicoes_tp_final.csv`

Devido ao processo de correção automática, trabalhos enviados em formatos diferentes do especificado, incluindo nomes incorretos de arquivos, ausência de arquivos obrigatórios ou estrutura de pastas divergente, **não** receberão nota no tópico de avaliação de predições. É responsabilidade do aluno garantir a conformidade total com as instruções de formatação e nomeação.

Além disso, será mantida uma planilha online de acompanhamento, atualizada consistentemente até a data final de entrega. Essa planilha exibirá as métricas de predição de cada aluno, permitindo o acompanhamento do desempenho individual e a comparação de resultados entre colegas ao longo do período de avaliação.

Regras de Uso de Ferramentas e Bibliotecas

Durante o desenvolvimento do trabalho, é **permitido** utilizar livremente bibliotecas e frameworks de aprendizado de máquina e ciência de dados, como **pandas**, **numpy**, **scikit-learn**, **xgboost**, **matplotlib**, **seaborn**, entre outras.

No entanto, é **estritamente proibido** o uso de modelos de linguagem ou ferramentas baseadas em inteligência artificial generativa, como ChatGPT, Copilot, Gemini, Claude, entre outros, para escrever, gerar ou revisar código, análises ou textos do trabalho.

Critérios de Avaliação

A avaliação do trabalho será baseada na qualidade técnica, clareza das análises e aderência às boas práticas de projetos de aprendizado de máquina. Cada entrega será pontuada considerando os seguintes critérios:

1) Notebook Completo (.ipynb)

Peso: 40% da nota final.

- **Estrutura e organização:** clareza na separação das etapas (carregamento, análise exploratória, preparação, modelagem, avaliação);
- **Correção técnica:** código funcional, reproduzível e com lógica consistente;

- **Análise exploratória:** profundidade na interpretação dos dados, uso adequado de estatísticas descritivas e visualizações informativas;
- **Engenharia de features e pré-processamento:** justificativas coerentes para as transformações aplicadas e tratamento correto de valores faltantes;
- **Modelagem e tuning:** experimentação estruturada com diferentes modelos, validação adequada e comparação transparente de resultados (que justifiquem a escolha do modelo e parâmetros finais).

2) Relatório PDF (no máximo 5 páginas)

Peso: 30% da nota final.

- **Clareza da comunicação:** apresentação objetiva dos resultados e conclusões;
- **Capacidade de síntese:** destaque dos achados mais relevantes da análise e da modelagem, sem excesso de detalhes técnicos;
- **Visualização:** uso adequado e legível de gráficos, tabelas e ilustrações para apoiar as conclusões;
- **Contextualização:** coerência com a narrativa do Jardim Comunitário Raízes Vivas e capacidade de traduzir os resultados em recomendações compreensíveis para a comunidade;
- **Linguagem e formatação:** texto claro, estruturado e formal, com revisão adequada.

3) Arquivo CSV de Predições (.csv)

Peso: 30% da nota final.

- **Formato:** Presença obrigatória das colunas `id` e `y_pred`, exatamente no formato solicitado. Devido ao uso de correção automática, entregas fora do formato especificado não serão avaliadas neste tópico;
- **Desempenho do modelo:** Qualidade preditiva avaliada por métricas automáticas durante a correção. ;
- **Reprodutibilidade:** Coerência entre o modelo descrito no notebook e as previsões geradas no arquivo final.

A nota final refletirá tanto a qualidade técnica das soluções quanto a clareza da comunicação e a coerência metodológica do trabalho. Trabalhos que demonstrem rigor analítico, boa documentação e capacidade de transformar dados em insights práticos serão particularmente valorizados.

Cronograma Parcial de Entregas e Acompanhamento de Métricas

Haverá 2 entregas parciais de predições do modelo e uma entrega final. O envio das predições em **pelo menos uma das entregas preliminares é obrigatório**, sendo a segunda entrega opcional, mas fortemente recomendada. Cada entrega parcial possui uma tarefa diferente no Moodle. Essa dinâmica tem como objetivo incentivar o aprimoramento contínuo, o acompanhamento do progresso e a comparação de resultados ao longo do tempo. O calendário completo de entregas será conforme abaixo.

Descrição	Data
Entrega parcial 1 das predições	09/11
Publicação do ranking 1	10/11
Entrega parcial 2 das predições	23/11
Publicação do ranking 2	24/11
Entrega final das predições	02/12
Publicação do ranking final	03/12
Discussão dos resultados (em sala)	03/12
Entrega do relatório + notebook	05/12

Após cada submissão, as métricas automáticas de desempenho dos modelos serão calculadas e disponibilizadas publicamente, permitindo que cada aluno acompanhe sua evolução técnica e avalie o impacto das melhorias implementadas entre as semanas. As top-3 equipes receberão pontos extras.

Os resultados das entregas parciais serão publicados em uma planilha que ficará disponível no Moodle.